

Projekt zaliczeniowy – Sztuczna inteligencja

Autor: Weronika Zimna

Kierunek: Informatyka

Rok/Sem: 3/6

1. Opis problemu

Celem projektu było rozwiązanie klasycznego problemu rekomendacji treści. Zadaniem stworzonego systemu jest znalezienie i wskazanie dla wybranej przez użytkownika książki k innych pozycji ze zbioru danych, które są do niej najbardziej zbliżone pod kątem cech mierzalnych (fizycznych i statystycznych)

2. Opis danych

W projekcie wykorzystano rzeczywisty i publicznie dostępny zbiór danych Goodreads-books z serwisu Kaggle, który zawiera szczegółowe informacje o ponad 10 000 książek. Na potrzeby algorytmu numeryczne dane zostały poddane czyszczeniu, a do obliczeń wyselekcjonowano wyłącznie trzy kluczowe cechy liczbowe:

- `average_rating` (średnia ocena czytelników),
- `num_pages` (objętość książki / liczba stron),
- `ratings_count` (łączna liczba oddanych głosów – wskaźnik popularności).

3. Uzasadnienie wyboru algorytmu

Do zrealizowania zadania wybrano algorytm **k-Nearest Neighbors (k-NN)**. Decyzja ta podyktowana była kilkoma czynnikami:

- Jest to intuicyjna metoda uczenia maszynowego (oparta na instancjach), która idealnie nadaje się do szukania podobieństw w wielowymiarowej przestrzeni mierzalnych cech.
- Algorytm ten cechuje się dużą prostotą matematyczną, co pozwoliło na jego pełną, samodzielną implementację "od zera" wyłącznie przy użyciu biblioteki NumPy, co było kluczowym wymogiem regulaminu projektu.
- Jako model typu *lazy learning* nie wymagał on czasochłonnego procesu trenowania sieci

4. Krótkie wyjaśnienie działania metody

Algorytm k-NN traktuje każdą książkę z bazy danych jako wektor (punkt) w trójwymiarowej przestrzeni cech (ocena, strony, popularność). Podobieństwo między książką docelową a resztą zbioru mierzone jest za pomocą odległości euklidesowej – im mniejszy dystans między punktami, tym książki są do siebie bardziej podobne. Krytycznym elementem zaimplementowanej metody jest normalizacja Min-Max. Ponieważ liczba stron osiąga wartości rzędu kilkuset, a oceny zaledwie od 1 do 5, brak normalizacji spowodowałby całkowite zdominowanie obliczeń przez liczbę stron. Znormalizowanie danych sprowadziło wszystkie wartości do wspólnego przedziału $[0, 1]$

5. Opis przeprowadzonych testów i uzyskane wyniki

W celu weryfikacji poprawności działania algorytmu przeprowadzono eksperyment badający zachowanie systemu dla zapytań o bardzo specyficznym profilu cech. Zapytanie testowe: Wpisano mroczny thriller "*The Silence of the Lambs*" (Thomas Harris). Jest to wydanie zbiorcze, które charakteryzuje się dużą objętością stron oraz wyjątkowo wysoką oceną czytelników.

Uzyskane wyniki (Najlepsze 3 rekomendacje dla $k=5$):

1. *The Complete Short Novels* – Anton Chekhov (Ocena: 4.47)
2. *The Collected Works of C.S. Lewis* – C.S. Lewis (Ocena: 4.45)
3. *Walking with the Wind* – John Lewis (Ocena: 4.49)

6. Wnioski

Implementacja algorytmu zakończyła się pełnym sukcesem pod względem inżynierskim i matematycznym. Algorytm k-NN działa bezbłędnie na liczbach – zamiast sugerować inne thrillery (co wymagałoby zaawansowanej analizy tekstu), system precyzyjnie odnalazł w przestrzeni cech "matematycznych bliźniaków". Znalazł inne obszerne wydania zbiorcze klasyków o niemal identycznej, wybitnie wysokiej ocenie (około 4.47). Głównym wnioskiem płynącym z eksperymentu jest to, że jakość rekomendacji zależy w 100% od odpowiedniego doboru cech wejściowych (*feature selection*). Algorytm oparty na gabarytach książki sprawdza się matematycznie, jednak jest ślepy na kontekst literacki. Aby w przyszłości system polecał książki z tego samego gatunku, należałoby rozbudować bazę danych o techniki przetwarzania języka naturalnego, np. *One-Hot Encoding* dla gatunków literackich.